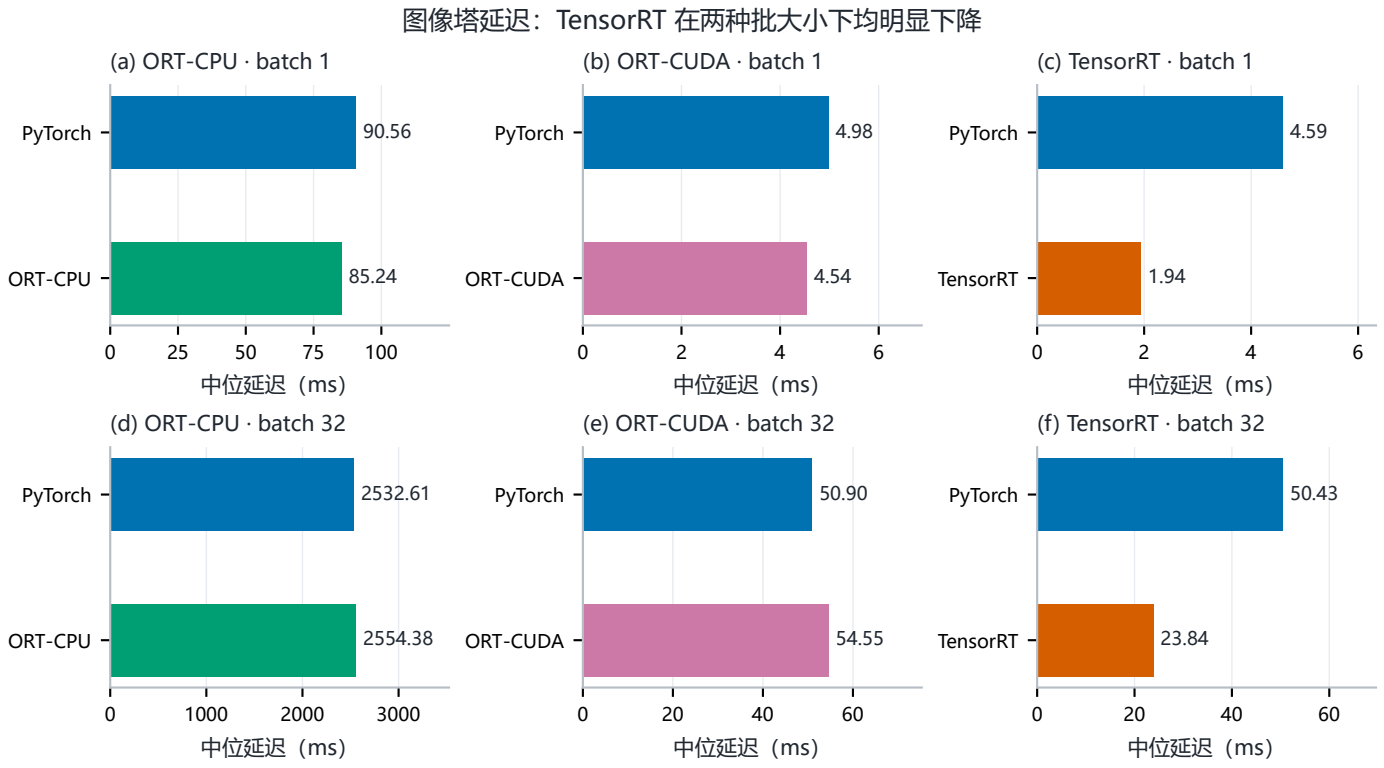
图像塔延迟：TensorRT 在两种批大小下均明显下降
(a) ORT-CPU · batch 1
PyTorch
ORT-CPU
90.56
85.24
0
25
50
75
100
中位延迟（ms）
(b) ORT-CUDA · batch 1
PyTorch
ORT-CUDA
4.98
4.54
0
2
4
6
中位延迟（ms）
(c) TensorRT · batch 1
PyTorch
TensorRT
4.59
1.94
0
2
4
6
中位延迟（ms）
(d) ORT-CPU · batch 32
PyTorch
ORT-CPU
2532.61
2554.38
0
1000
2000
3000
中位延迟（ms）
(e) ORT-CUDA · batch 32
PyTorch
ORT-CUDA
50.90
54.55
0
20
40
60
中位延迟（ms）
(f) TensorRT · batch 32
PyTorch
TensorRT
50.43
23.84
0
20
40
60
中位延迟（ms）