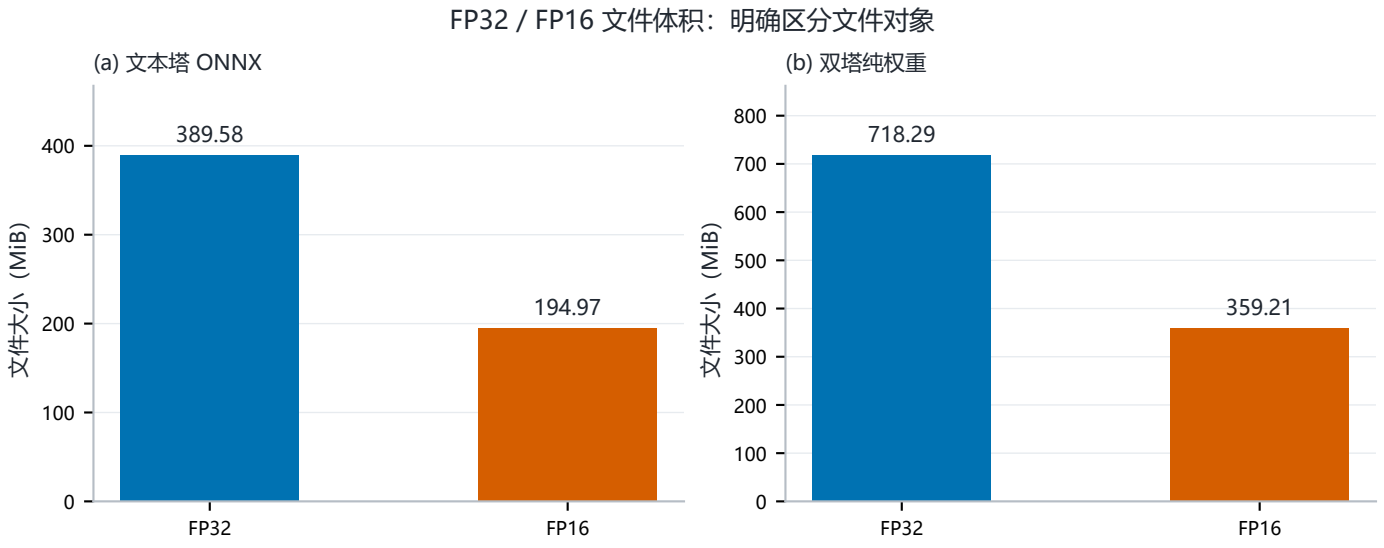
FP32 / FP16 文件体积：明确区分文件对象
(a) 文本塔 ONNX
文件大小（MiB）
0
100
200
300
400
389.58
194.97
FP32
FP16
(b) 双塔纯权重
文件大小（MiB）
0
100
200
300
400
500
600
700
800
718.29
359.21
FP32
FP16