西 安 邮 电 大 学

AI 全栈开发实验

题目：模型设计与训练实验

组　　号：**23**

组员信息：

学号	姓名	分工
2610321101	何朝杨	Chinese-CLIP 使用指南与实验报告撰写排版、图表制作
2610321103	杜军博	检索模型集成与评测（检索模块、FAISS 索引、三路融合检索、AI 评测管线）
2610321135	王陆洲	模型微调训练与优化（微调数据转换、训练执行、NoDDP 补丁、权重评测）
2610320046	张梓萱	训练数据构建与划分核验
2610320033	刘凡思雨	训练过程记录与结果数据核对
2610321168	秦鑫洋	实验报告校对与图表整理

时　　间：**2026.10.20**

一、实验目的

本实验面向“电商商品多模态推荐与上架 Agent”课题的模型环节，在实验一构建的数据基座上完成中文图文检索模型的设计、训练与适配，具体目的如下：

1. 掌握深度学习框架的安装与开发环境部署：在 WSL2 与 Docker 容器内配置 CUDA 版 PyTorch 与 Chinese-CLIP 训练环境[1]，解决显存、分布式通信等实际工程问题；
2. 掌握多模态模型选型方法：针对电商图文检索任务，比较计算机视觉模型（ViT[2] 与 CNN）、自然语言处理模型（RoBERTa-wwm[3]）与多模态对比学习框架（CLIP[4]），最终选定“双塔编码 + 对比学习”的多模态方案；
3. 掌握训练优化方法：运用混合精度、梯度检查点、学习率预热与训练过程监控等计算效率优化与梯度控制手段，在 8GB 显存单卡约束下完成稳定微调；
4. 掌握小样本与非标数据的模型适配策略：用实验一清洗产出的 9,393 条领域图文数据做迁移微调，以属性模板文本统一非标标题的文本分布，缓解通用预训练模型在电商垂直域的泛化问题；
5. 完成模型评测与落地衔接：以 Recall@K 等指标量化微调前后差异，形成“数据-模型-指标”的完整证据链，并将微调权重接入检索索引，为实验三的量化剪枝与后续 Agent 开发铺垫。

二、实验环境

软硬件环境

1. 硬件：NVIDIA GeForce RTX 5060 Ti（8GB 显存，compute capability 12.0）单卡工作站；
2. 操作系统/容器：Windows 11 宿主机，训练在 WSL2 内的 Docker 容器中完成，镜像为 `pytorch/pytorch:2.7.1-cuda12.8-cudnn9-devel`；
3. 软件：容器内 Python 3.11（conda 环境）与 torch 2.7.1+cu128 构成主要开发栈，主机端使用 PyCharm 与 Git；
4. 核心库：numpy 1.26.4、timm 1.0.30、lmdb 1.3.0（源码编译）、faiss[5]，以及施加了本地 NoDDP 补丁的 Chinese-CLIP 官方实现[1]；
5. 模型：Chinese-CLIP ViT-B-16 预训练权重 `clip_cn_vit-b-16.pt`（719MB）；
6. 数据：实验一产出的 9 类 9,393 条图文对（LMDB 打包约 1.2GB），由 `scripts/build_retrieval_dataset.py` 转换为检索训练数据集并按 8:1:1 划分。

三、实验内容与步骤

本实验内容涵盖任务书的四个部分（第四部分为选做），需要至少覆盖前三部分：

3.1 环境部署：深度学习框架安装、开发工具与环境

3.2 模型选型：计算机视觉模型、自然语言处理模型、多模态/多任务模型

3.3 训练优化方法：计算效率优化、梯度控制方法、训练过程控制

3.4 模型适配策略：解决小样本/非标数据的泛化问题（选做）

以下按需求分析、设计思路、代码实现、测试优化四个方面展开。

3.5 需求分析

本课题的检索推荐与上架 Agent 要求模型具备“给定一句话或一张图即可定位商品”的能力，模型侧需求可归纳为四个方面：

1. 检索能力需求：模型需支持中文文本搜商品图（文搜图）与以图搜图两类检索形态，输出可比对的图文嵌入向量，并直接对接实验一落盘的 FAISS 检索链路[5]；
2. 域适配需求：预训练 Chinese-CLIP 面向通用中文图文，对电商属性化表述（颜色、材质、细分类）的区分度不足，零样本基线在本数据 test 划分上 R@1 仅 37.37，必须借助领域数据微调；
3. 训练约束：数据仅 9,393 条、单卡 8GB 显存，训练方案必须兼顾过拟合控制、显存占用与可复现性；
4. 评测需求：需给出微调前后的 Recall@K 量化对比，口径严谨、可复算，并保留训练凭证。

3.6 设计思路

整体训练流水线如图 1 所示：实验一的清洗数据经属性模板文本构建与哈希划分后打包为 LMDB，微调 Chinese-CLIP 后在 test 划分评测，最后用新权重重建检索索引。

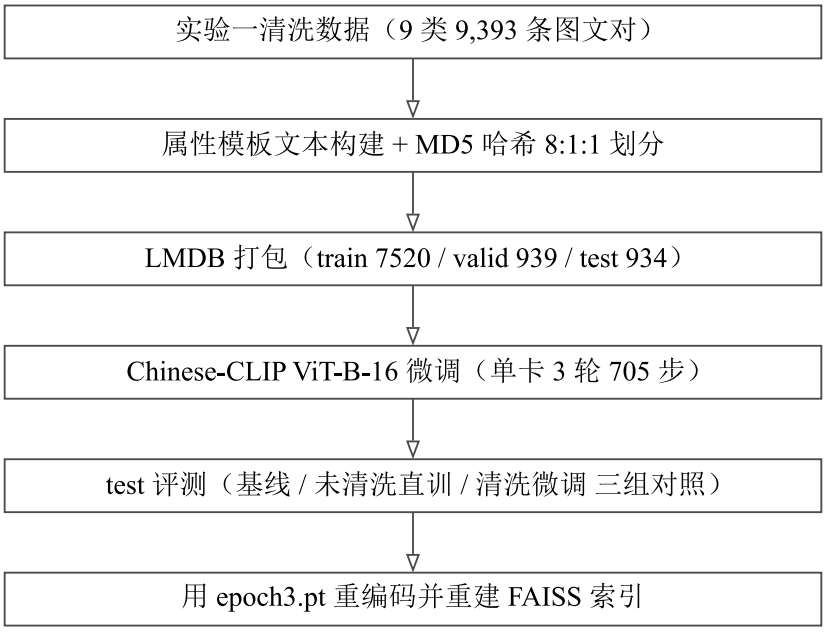


图 1 微调训练流水线

模型采用 Chinese-CLIP 双塔结构[1,4]，如图 2 所示：视觉塔 ViT-B-16[2] 编码商品图片，文本塔 RoBERTa-wwm-ext-base-chinese[3] 编码属性模板文本，两路特征经 L2 归一化后以双向 InfoNCE 对比损失联合微调。

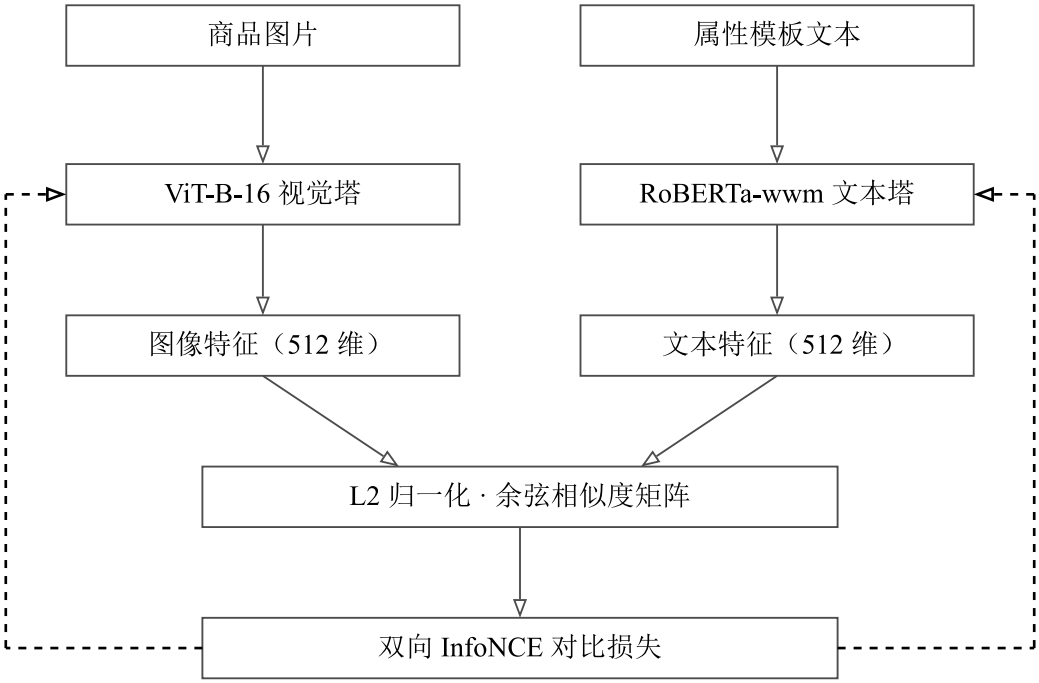


图 2 Chinese-CLIP 双塔模型架构

数据侧与训练侧的主要设计决策如下：

1. 属性模板文本统一文本分布：商品大类、细分类、颜色、材质与标题五段式属性模板与构建 FAISS 索引共用同一文本生成函数，使文本塔学到结构化属性表达，同时顺带适配非标标题；
2. MD5（item_id）哈希划分 8:1:1：同一商品永远落在同一划分，杜绝图文泄漏；
3. 全参微调而非冻结或 LoRA[6]：样本虽少但域差异大，双塔全参 3 轮即可收敛，且验证曲线未见过拟合；
4. NoDDP 单卡化改造：针对 WSL2 下 NCCL 集合通信挂死的问题，以 NoDDP 包装器保留 `module.` 前缀，兼容官方特征导出脚本，训练代码零侵入降级。

3.7 代码实现

3.7.1 环境部署

Docker 容器内配置 CUDA 版 PyTorch 后，克隆 Chinese-CLIP 官方代码并施加 3 处本地补丁，分别是新增 `no_ddp.py`、将 `main.py` 的建组条件化、使 `train.py` 验证阶段的 `all_reduce` 仅在多卡时执行；lmdb 在镜像内源码编译（无预编译 wheel）。训练与评测入口如代码 1 所示，单卡训练约 6 分钟，评测约 3 分钟。

```
# 训练（单卡约 6 分钟）
bash scripts/finetune/run_train_single_gpu.sh
# 评测（约 3 分钟）
bash scripts/finetune/run_test_eval.sh
```

代码 1 训练与评测入口命令

3.7.2 模型选型

模型选型从计算机视觉、自然语言处理与多模态三个角度比较。视觉塔选 ViT-B-16[2] 而非 CNN（ResNet50），因其与官方中文 CLIP 预训练权重严格对齐，且全局注意力对商品整体形态与配件构成的建模更稳定；文本塔选 RoBERTa-wwm-ext-base-chinese[3]，全词掩码预训练对“双肩包/保温杯”这类属性词更敏感，且是 Chinese-CLIP 的官方文本塔；多模态框架选 CLIP 对比学习[4] 的中文实现 Chinese-CLIP[1]，备选的检测/分类模型只能输出类别标签、无法提供可检索的嵌入，纯文本检索则丢失图像模态，而双塔对比学习得到的图文嵌入空间天然支持文搜图与图搜图，与本课题检索任务对口。

3.7.3 训练优化方法

训练优化沿计算效率、梯度控制与过程控制三条线展开。计算效率上启用 amp 混合精度训练，并以梯度检查点（grad checkpointing）用时间换显存。这是 8GB 显存稳定运行 batch 32 的前提；同时以 `--skip-aggregate` 跳过多卡聚合。梯度控制上，学习率 1e-5、权重衰减 0.001、warmup 100 步后线性衰减，与官方 MUGE 微调脚本[1] 对齐，防止小样本下大步长破坏预训练表征。过程控制上每 150 步执行一次验证、每个 epoch 保存一次检查点、固定随机种子 123，并监控 valid loss 与 batch 内两路准确率，出现过拟合即早停（实测未出现）。其余超参数为 batch 32、valid batch 32、最大训练轮数 3、上下文长度 52、累计步数 1、数据加载线程 2，完整快照由训练脚本自动写出 `params_*.txt`。

3.7.4 模型适配策略

针对小样本与非标数据的泛化问题，适配策略包含迁移学习、文本分布对齐、防泄漏划分与数据纯度兜底。迁移学习以中文图文预训练权重为起点，仅用 7,520 条训练样本、3 轮 705 步即达到目标指标。文本分布对齐把非标商品标题经属性模板重写为五段式结构化文本（见代码 2），将自由文本的长尾写法收敛到可控分布。防泄漏划分由 `split_by_hash` 以 MD5（item_id）决定划分，重复商品不会跨集合（见代码 3）。数据纯度兜底依赖实验一的视觉清洗（置信度 0.72），预先排除 765 条脏样本。小样本场景下“少而纯”优于“多而杂”。图像几何/光学增强（`--use-augment`）因 timm 1.0 API 兼容性未验证而关闭，先保证训练链路稳定，留待后续启用。

```
    def build_product_text(row):
        """四属性固定输出，标题存在则追加，与建索引同函数。"""
        parts = [f"{label}: {row.get(field)}" for label, field in FIELD_LABELS]
        # FIELD_LABELS = [("商品大类", "product_type"), ("细分类", "type"),
        #                 ("颜色", "color"), ("材质", "material")]
        if row.get("item_name"):
            parts.append(f"商品标题: {row['item_name']}")
        return "; ".join(parts)
```

代码 2 属性模板文本构建函数（与建索引同函数）

```
def split_by_hash(item_id: str, train_ratio: float, valid_ratio: float) -> str:
    """按 item_id 的 MD5 哈希值切分,保证同一 item_id 永远落在同一划分。"""
    digest = hashlib.md5(item_id.encode("utf-8")).hexdigest()
    value = int(digest, 16) % 1000 / 1000.0  # 0.000 ~ 0.999
    if value < train_ratio:
        return "train"
    if value < train_ratio + valid_ratio:
        return "valid"
    return "test"
```

代码 3 按 item_id 哈希划分训练/验证/测试集

3.8 测试优化

测试与优化工作集中在四个方面：

1. NCCL 挂死定位：WSL2 下 `init_process_group` 正常但首次集合通信永久卡死，多种 NCCL 环境变量无效，最终以 NoDDP 单卡改造绕过，并验证检查点的 `module.` 前缀可被官方 `extract_features.py` 直接加载（已实测）；
2. 显存溢出处置：开启 amp 与梯度检查点后，8GB 显存可稳定跑 batch 32；
3. 工具链冲突：torchrun 2.6 起 `--logs-specs` 与官方脚本的 `--logs` 前缀冲突，改用 `python` 直接启动并手动注入 `RANK/WORLD_SIZE` 等环境变量；
4. 评测复现：`run_test_eval.sh` 自动把分数、参数快照与训练日志同步到 `docs/finetune/runs/`，`run_manifest.json` 记录权重路径与字节数，确保评测结果可复算。单卡 3 轮训练约 6 分钟、test 评测约 3 分钟，可支撑快速迭代。

四、实验关键技术与难点

WSL2 环境下 NCCL 集合通信挂死的绕过是本实验最大的工程难点：`init_process_group` 正常但首次集合通信永久卡死，多种 NCCL 环境变量均无效。为此设

计了 NoDDP 包装器，保留 `model.module` 访问方式与 `module.` state_dict 前缀，使训练侧无感降级、导出侧零修改兼容，避免为单卡重写官方训练代码。

8GB 显存约束下的训练配置采用混合精度与梯度检查点的组合，用约 1.5 倍训练时长换取 batch 32 的稳定运行，避免小 batch 下对比学习负样本不足导致的性能损失。

小样本全参微调的过拟合控制依赖 1e-5 低学习率、100 步 warmup 与 3 轮短训的组合，并配合逐 150 步的验证监控。训练全程 valid loss 单调下降、准确率持续上升，未见过拟合拐点。

属性模板文本设计把非标电商标题重写为“大类/细分类/颜色/材质/标题”五段式结构化文本，既统一了训练与检索的文本口径，也把文本塔的容量集中到区分性属性上。

评测口径的严谨性同样构成难点：batch 内 32 候选的验证准确率与 934 全候选的 R@K 不可混比，且 test 划分只允许使用一次，后续调参只能看 valid，以防止“提升 21 个点”的结论被测试集污染。

五、实验结果与分析

本部分基于实验一的数据集完成模型微调，依次给出数据-模型关联表、基于原始数据与增强数据的对比实验、训练优化的前后对比、模型适配策略的实验验证、关联实验一预处理环节的问题分析，最后补充检索集成与试点评测结果。

（一）数据-模型关联表

实验一数据集特点（样本量、增强方式等）与本实验模型选型/优化策略的对应关系见表 1。

数据维度	实验一数据集特点（样本量/增强方式）	实验二模型选型/优化策略
样本量	原始 10,165 条 → 增强后 9,393 条；train/valid/test = 7520/939/934	小样本迁移：预训练权重 + 1e-5 低学习率 + 3 轮短训，验证监控防过拟合
图文配对	9 大类，图片与文本一一配对	双塔对比学习[1,4]：图文对即正样本对，batch 内互为负样本
文本增强	DeepL 中文译文 + 属性模板五段式（大类/细分类/颜色/材质/标题）	RoBERTa-wwm 中文文本塔[3]，输入分布收敛后属性词区分度提高
图像增强	ISNet 抠图、SHA-256 去重、技术质检（image_status 全 ok）	视觉塔用原图训练（增强体现在数据纯度）；几何/光学增强暂缓，避免引入未验证变量
属性增强	GPT 视觉清洗补全 type/color/material，置信度阈值 0.72	结构化属性进入模板文本，把文本塔容量集中到区分性属性上
数据纯度	视觉清洗排除 765 条非目标商品（通过率 92.4%）	对比学习正样本对不错配，图文对齐信号不被稀释
划分方式	按 item_id 的 MD5 哈希 8:1:1 划分	无泄漏评测：同一商品不跨集合，Recall@K 结果可信

表 1 数据-模型关联表（实验一样本量/增强方式 ↔ 实验二选型/优化策略）

（二）对比实验：基于原始数据与增强数据验证数据增强对模型性能的提升

对比分数据与模型两个层次。数据层逐项对比实验一预处理前的原始数据与增强后的数据（见表 2），这是“数据增强”的自变量本身。模型层在同一模型架构、同一配方（bs32、lr 1e-5、3 轮、seed 123）、同一评测协议（test 934 条文搜图、候选池 934）下给出三组对比：预训练基线（未训练）、未清洗数据直训（用预处理前 10,165 条训练）、清洗数据微调（用增强后 9,393 条训练），由此把总提升拆分为“微调本身”与“数据清洗净贡献”两部分（见表 3、图 3）。

维度	原始数据（实验一预处理前）	增强数据（实验一预处理后）	对模型训练的影响
样本量	10,165 条，混有脏数据与非目标商品	9,393 条（通过率 92.4%，排除 765 条）	样本略减，但图文对齐信号纯度显著提高
文本	原始标题（Amazon 为英文、规格尾巴多、写法长尾）	DeepL 中文译文 + 属性模板五段式文本	文本塔输入分布收敛，域内属性词可学
图片	存在重复图与个别低质图	SHA-256 去重、技术质检全部可读	视觉塔不重复学习同一张图，输入质量有保底
属性	颜色/材质缺失或“未知”，无细分类	GPT 视觉清洗补全 type/color/material（阈值 0.72）	模板中的属性词有图/文依据，区分度提高
主体纯度	混入配件与非目标商品（水杯类约两成）	视觉清洗按“图片为准”排除 765 条	对比学习正样本对不错配，噪声不进训练

表 2 原始数据与增强数据逐项对比（基于实验一预处理环节）

模型层对比结果见表 3 与图 3。

指标	预训练基线	未清洗直训	清洗微调	直训增益	清洗增益
R@1	37.37	50.96	58.67	+13.59	+7.71
R@5	70.77	84.48	89.08	+13.71	+4.60
R@10	82.44	93.04	96.90	+10.60	+3.86
mean_recall	63.53	76.16	81.55	+12.63	+5.39

表 3 test 集 Recall@K 三组对照（文搜图，934 条）。直训增益 = 未清洗直训 − 预训练基线；清洗增益 = 清洗微调 − 未清洗直训

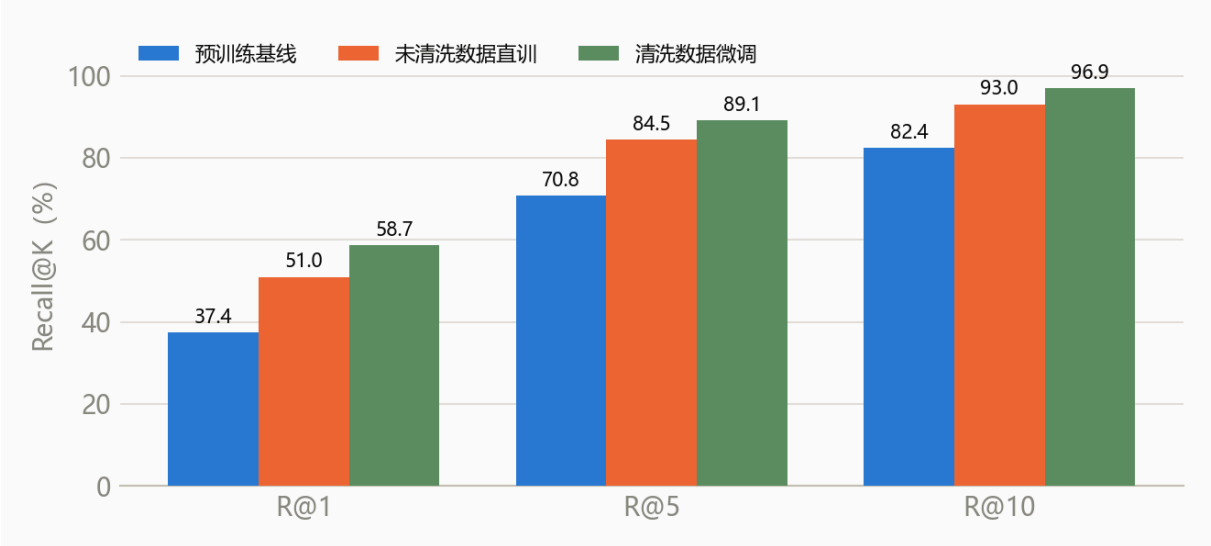


图 3 三组模型 Recall@K 对比（test 934 条）

围绕“数据增强 → 模型性能提升”的因果链由三组对照支撑，可从对照设计、总效应、归因与机制逐层展开。

对照设计上，三组唯一的差异是训练所用的数据：预训练基线未接触实验一任何数据；未清洗直训用预处理前的原始表（10,165 条）训练；清洗微调用视觉清洗与属性增强后的数据（9,393 条）训练。后两组配方完全相同（bs32、lr 1e-5、3 轮、seed 123），只换数据。

总效应上，R@1 从 37.37 提升到 58.67（+21.30 个百分点，相对 +57.0%），R@5、R@10、mean_recall 同步提升（见表 3）。

归因上，仅用未清洗数据直训，R@1 已达 50.96（+13.59 个百分点，相对 +36.4%），即总提升中约 64% 来自“预训练权重 + 域内小样本微调”这一域适配训练，与数据质量无关。从未清洗直训的 50.96 到清洗微调的 58.67（+7.71 个百分点）是数据清洗的净贡献，占总提升约 36%。清洗后样本由 10,165 减到 9,393（少 772 条），样本变少而效果更好，说明该场景下“质量优于数量”。各 K 值的清洗增益同向但幅度递减：R@1 为 +7.71、R@5 为 +4.60、R@10 为 +3.86，K 越宽松增益越小，符合“清洗主要改善最难的首位命中”的预期。

机制上，视觉清洗排除 765 条非目标商品（水杯类约两成），避免错误正样本对稀释对比学习信号；属性模板把自由标题收敛为五段式结构化文本（见表 2 文本行），使文本塔能对颜色、材质、细分类形成稳定编码。两点共同解释上述 +7.71 的净增益。数据层证据是排除率与通过率，模型层证据是 valid loss 全程单调下降、无噪声平台（见图 4）。

就评测口径而言，R@10 已达 96.90、接近饱和，后续对比建议以 R@1 或 mean_recall 为主指标。候选池仅 934 条，数字不能与官方 MUGE 十万级榜单横向比较；test 文本与训练同分布（同一属性模板），换成真实用户自由输入时增益会小于本表数字。

（三）训练优化的前后对比

训练过程 7 次验证的主要指标见表 4 与图 4。Valid Loss 从 0.2225 降至 0.1403（-36.9%），Image2Text Acc 从 91.77% 升至 94.69%、Text2Image Acc 从 91.25% 升至 94.48%，全程无回升、无过拟合拐点，第 3 轮末仍在改善。中途（epoch2 @ 300 步）loss 小幅回弹属 warmup 后正常波动，随后单调下降，说明梯度控制参数（1e-5 / warmup 100 / wd 0.001）设置合理。训练效率方面，705 步（7520/32×3）约 6 分钟完成，混合精度与单卡化改造没有牺牲收敛质量。

训练步数	Valid Loss	Image2Text Acc（%）	Text2Image Acc（%）
150（epoch1）	0.2225	91.77	91.25
235（epoch1）	0.1963	93.33	92.19
300（epoch2）	0.2056	91.87	92.50
450（epoch2）	0.1571	94.58	93.44
470（epoch2）	0.1543	94.90	93.75
600（epoch3）	0.1444	94.48	94.27
705（epoch3）	**0.1403**	**94.69**	**94.48**

表 4 训练过程验证指标（batch 内 32 候选口径，与全候选 R@K 不可直接比较）

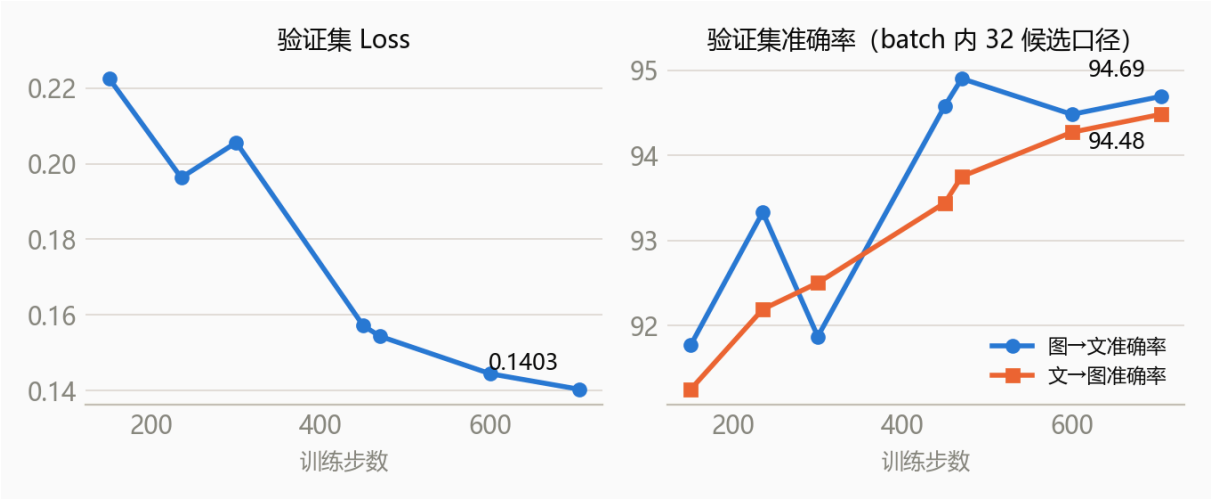


图 4 训练过程验证曲线：Loss 下降与两路准确率上升（7 次验证记录）

（四）模型适配策略的实验验证

小样本迁移的有效性由三组对照给出：仅 7,520 条清洗训练样本、3 轮即把 R@1 提升 21.30 个百分点（见表 3），其中约 64% 来自“预训练权重 + 域内小样本微调”的域适配训练，验证适配策略成立。非标文本的适配性体现在属性模板把自由标题收敛为五段式结构化文本后，test 同分布 R@1 达 58.67（见图 3）。同时需如实说明，该口径含“适配模板写法”成分，真实自由查询下的增益需要后续端到端评测补充。划分的可靠性由 MD5 哈希划分保证，训练/验证/测试为 7520/939/934 条且零泄漏。结果已可落地：微调权重重新编码全部 9 类 9,393 条商品并重建 FAISS 索引（`data/index_data_finetuned/`，各类 errors 均为 0），适配结果直接接入检索链路。

（五）问题分析：与实验一预处理环节的关联

训练与评测中暴露的问题均可回溯到实验一的预处理环节。

水杯类检索难度最高，根源在实验一视觉清洗中该类通过率最低（79.9%，504 条被排除），搜索来源混入杯盖、杯刷等配件与非目标商品。这正是视觉属性清洗环节的价值：若缺该环节，这些样本会以错误正样本对进入对比学习，直接拉低水杯类的检索精度。

4 条待复核记录源自清洗期间视觉模型 API 临时 404，属工程问题而非数据问题。实验一“审计日志（model_audit.jsonl）+ is_readed 断点续跑”的设计使该问题可追溯、可重试，未污染训练集。Amazon 四类（手机壳/厨房用品/鞋/家居用品）的文本塔输入依赖实验一跨语言统一环节的 DeepL 译文，译文质量直接影响这些类目的文搜图效果，逐条翻译审计保证可复查。

test 与训练同分布（均出自属性模板）是实验一文本描述生成环节的双刃剑：同分布指标被抬高，真实自由查询的增益会打折，需要端到端评测补齐。覆盖率方面，女装正式表 361 条、清洗仅覆盖 358 条，缺的 3 条在审计中有结论但未入通过表，提示预处理覆盖率应作为训练数据清单的核对项。本实验 9,393 条训练样本全部有据可查。

（六）检索集成与补充试点评测

模型级 test 评测验证了 checkpoint 本身的图文对齐能力。为检查微调权重接入商品索引后的实际行为，仓库另保存了一轮独立的 AI 复核检索试点（`evaluation/retrieval/results/runs/deepseekv4_1_flash_pilot_20261018/`）：从 9 个类别生成 135 条文字、图片和图文查询，经 AI 有效性复核后纳入 132 条。最终形成 1,325 条相关性判断和 1,320 行 Top-10 排名结果，相关度采用 0–3 级（0 为不相关，1 为弱相关，2 为相关替代，3 为高度符合）。不同查询模式的指标见图 5 与表 5。

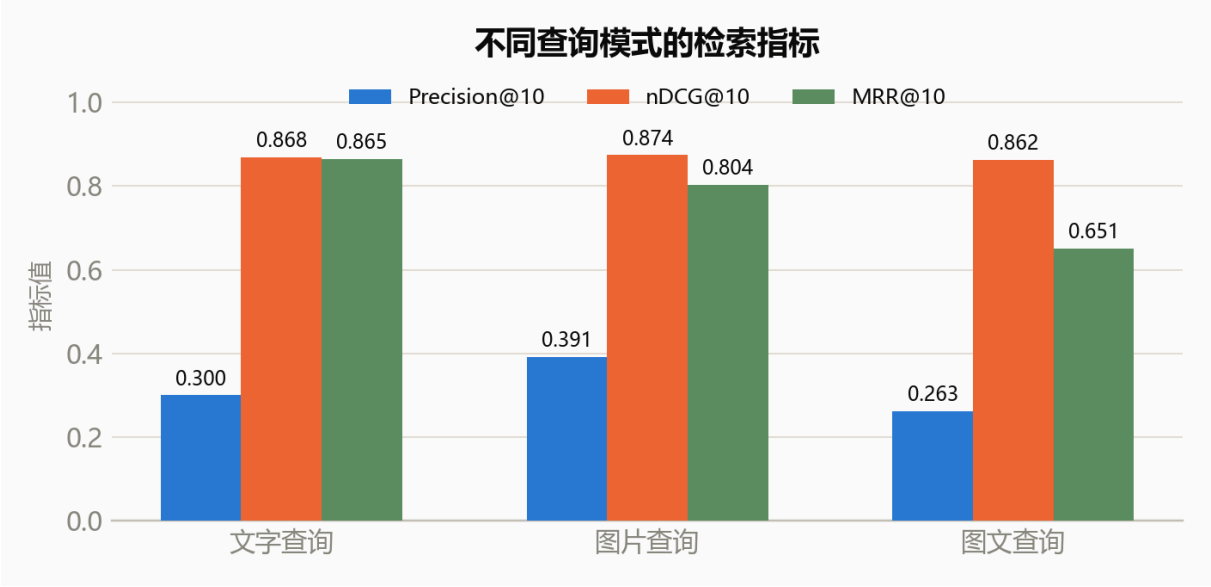


图 5 AI 复核检索试点的不同查询模式指标（用于权重调优，不是最终测试）

查询模式	有效查询数	Precision@10	nDCG@10	MRR@10
文字	44	0.300	0.868	0.865
图片	45	0.391	0.874	0.804
图文	43	0.263	0.862	0.651

表 5 AI 复核试点按查询模式汇总的指标

图片查询的 Precision@10（0.391）高于文字查询（0.300）和图文查询（0.263），文字查询的 MRR@10（0.865）最高。本轮尚不能据此断言图文融合优于单路检索，原因是查询由索引商品字段生成、相关性由 AI 评审，且图片/图文判断主要覆盖返回的 Top-10 候选。因此，这组结果只作为验证集调权重和错误分析的依据，不能替代人工真值或来源商品不重叠的最终测试集。后续调优必须固定 `inputs/queries.csv`、`inputs/qrels.csv`、索引、模型、Top-K 与候选数，每组权重使用新的 `run-id` 归档。

六、实验总结与展望

本实验完整走通了“环境部署 → 模型选型 → 训练优化 → 模型适配”的模型训练链路。在 WSL2 + Docker 的 8GB 显存单卡上搭建 Chinese-CLIP 训练环境，选定 ViT-B-16 + RoBERTa-wwm 双塔对比学习架构，以混合精度、梯度检查点、低学习率预热等手段稳定微调 3 轮。用实验一的 9,393 条清洗图文数据把 test R@1 从 37.37 提升到 58.67（相对 +57.0%），mean_recall 从 63.53 提升到 81.55，且全程未见过拟合。三组对照进一步拆分：总提升中微调本身贡献 +13.59 个百分点，数据清洗净贡献 +7.71 个百分点。微调权重已重建检索索引投入使用，训练凭证与评测归档完整入库、可复现，小组成员分工见封面表格。

通过本次实验，加深了对“数据-模型”关系的理解：实验一的清洗投入（排除 765 条脏样本）与属性增强（模板化描述）在模型端兑现为 +7.71 个百分点的清洗净增益（三组对照，占总提升约 36%），Data-Centric AI[7] 的理念在模型训练阶段得到直接验证。也体会到显存、分布式通信等工程约束对训练方案设计的实际塑造作用。

后续工作将从四个方面推进：

1. 启用图像增强与更大 batch 模拟（`--use-augment`、`accum_freq`），并把训练轮数延长到验证曲线平台期；
2. 用同一套查询集对比新旧索引的端到端召回，据此调优图文三路融合权重；
3. 在保持 R@1 的前提下开展量化与剪枝（实验三），压缩推理开销；
4. 面向 Agent 的工具化（实验四、五），把检索能力封装为工具，接入前后端与大模型编排。

七、参考文献

[1] YANG A, PAN J, LIN J, 等. Chinese CLIP: Contrastive Vision-Language Pretraining in Chinese[EB/OL]. (2022). https://arxiv.org/abs/2211.01335.

[2] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, 等. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[C/OL]//International Conference on Learning Representations (ICLR). 2021. https://openreview.net/forum?id=YicbFdNTTy.

[3] CUI Y, CHE W, LIU T, 等. Pre-Training with Whole Word Masking for Chinese BERT[J/OL]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 3504-3514. DOI:10.1109/TASLP.2021.3124365.

[4] RADFORD A, KIM J W, HALLACY C, 等. Learning Transferable Visual Models From Natural Language Supervision[C/OL]//Proceedings of the 38th International Conference on Machine Learning (ICML). 2021: 8748-8763. https://proceedings.mlr.press/v139/radford21a.html.
[5] JOHNSON J, DOUZE M, JÉGOU H. Billion-scale Similarity Search with GPUs[J/OL]. IEEE Transactions on Big Data, 2021, 7(3): 535-547. https://arxiv.org/abs/1702.08734. DOI:10.1109/tbdata.2019.2921572.
[6] HU E J, SHEN Y, WALLIS P, 等. LoRA: Low-Rank Adaptation of Large Language Models[C/OL]// International Conference on Learning Representations (ICLR). 2022. https://openreview.net/forum?id=nZeVKeeFYf9.
[7] MALERBA D, POGGI A, ALVIANO M, 等. Data-Centric AI Manifesto: How Data Quality Drives Modern AI[J/OL]. Electronics, 2026, 15(9): 1913. DOI:10.3390/electronics15091913.

附录 A 实验代码与结果目录

本附录列出本实验实际使用或用于复核的代码与结果文件位置。大体积权重、LMDB 和中间特征按仓库约定不入 Git；报告保留其路径、字节数和可重建命令，源文件以仓库当前版本为准。

A.1 关键代码入口

路径	作用	报告对应内容
`scripts/build_retrieval_dataset.py`	清洗数据转 TSV/JSONL，并按 item_id 的 MD5 哈希做 8:1:1 划分。	3.7 代码实现、五（一）、五（四）
`scripts/retrieval/text_builder.py`	生成与 FAISS 建索引一致的属性模板文本。	二、3.6 设计思路、五（二）
`scripts/retrieval/build_category_index.py`	用 Chinese-CLIP 编码图片/文本并生成分类 FAISS 索引。	3.6 设计思路、六
`scripts/retrieval/search_category_index.py`	执行文字、图片和图文三路融合检索。	五（六）、六
`scripts/finetune/run_train_single_gpu.sh`	单卡 3 轮微调入口，启用 AMP、梯度检查点和 NoDDP。	3.5 需求分析、3.7 代码实现、四
`scripts/finetune/run_test_eval.sh`	一次性生成预训练基线与微调 checkpoint 的 test 分数。	五（二）、五（三）
`scripts/finetune/patches/no_ddp.py`	单卡 DDP 替身，保留 module 前缀以兼容官方导出脚本。	3.5 需求分析、四
`evaluation/retrieval/code/evaluate_retrieval.py`	固定查询/qrels 后计算 Recall、Precision、nDCG、MRR。	五（六）
`evaluation/retrieval/code/run_gpt61sol_pilot.py`	生成查询、AI 复核候选并归档试点评测。	五（六）

表 6 实验二关键代码入口与报告对应关系

A.2 训练与模型级评测凭证

训练与模型级评测凭证位于 `docs/finetune/runs/2026-10-18_bs32_lr1e-5/`，包括完整训练日志、超参数快照、预训练基线分数、微调后分数和 `run_manifest.json`；指标归档位于 `evaluation/retrieval/results/runs/finetuned_epoch3_test_20261019/`，其中 `summary.json` 记录测试样本数 934、候选池 934、四项指标及限制条件。未清洗数据对照组的训练凭证位于 `docs/finetune/runs/2026-10-20_uncleaned_bs32_lr1e-5/`，指标归档位于 `evaluation/retrieval/results/runs/uncleaned_epoch3_test_20261023/`（含三组对照图表、`summary.json` 与 `测试结果说明.md`）。文件清单见表 7。报告不直接使用归档目录中的英文仪表盘图，而是由 `docs/scripts/gen_figures_exp2.py` 直接读取上述 JSON 与训练日志生成中文图（见图 6），保证图表文字、数据来源和报告口径一致。

文件	说明
out_2026-10-18-12-27-38.log	完整训练日志，含 7 次验证记录（`docs/finetune/runs/2026-10-18_bs32_lr1e-5/`）
params_2026-10-18-12-27-38.txt	运行时超参数快照（同上目录）
baseline_test_score.json	预训练权重 test 分数（同上目录）
finetuned_epoch3_test_score.json	epoch3 test 分数（同上目录）
run_manifest.json	权重路径、字节数、评测参数和分数（同上目录）
summary.json	模型级评测汇总（934 条 test，`.../finetuned_epoch3_test_20261019/`）
01_recall_at_k.png ～ 08_evaluation_dashboard.png	八张归档图表（召回、提升、验证趋势、收敛与诊断，同上目录）
render_eval_charts.py	图表重绘脚本（同上目录）
2026-10-20_uncleaned_bs32_lr1e-5/	未清洗对照组训练凭证（训练日志、参数快照、分数与 run_manifest，位于 `docs/finetune/runs/`）
uncleaned_epoch3_test_20261023/	三组对照评测归档与图表（summary.json、测试结果说明.md 等）

表 7 训练与模型级评测凭证文件清单

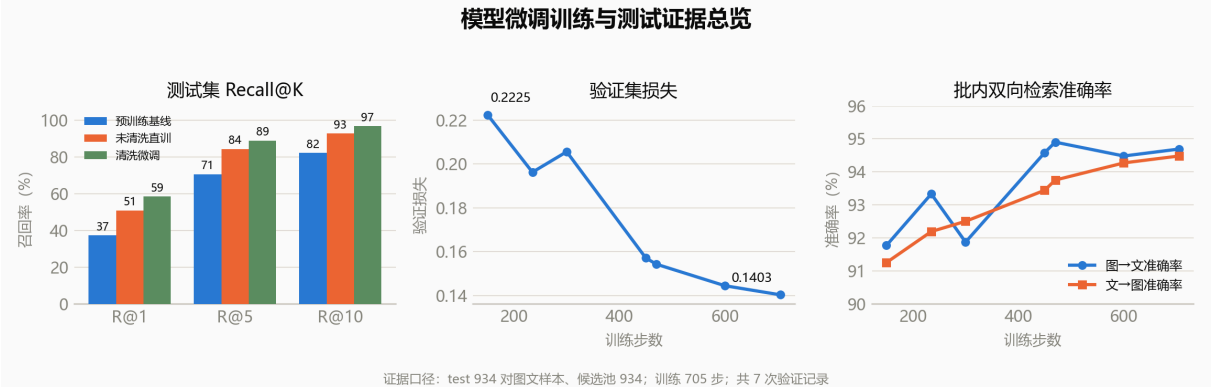


图 6 模型微调训练与测试证据总览：测试召回、验证损失与批内双向准确率

A.3 检索试点评测凭证

检索试点评测凭证位于 `evaluation/retrieval/results/runs/deepseekv4_1_flash_pilot_20261018/`，文件清单见表 8。

文件	说明
inputs/queries.csv	132 条有效查询
inputs/qrels.csv	唯一最终相关性标签
inputs/retrieval_config.json	本轮检索配置快照
ai_review.csv	query-item 相关性与理由
query_audit.csv	135 条查询的纳入/排除记录
ranked_results.csv	固定 Top-10 排名
query_metrics.csv	逐查询 Precision/Recall/nDCG/MRR
summary.json	按文字/图片/图文模式汇总
run_metadata.json	模型、索引、权重和运行设置
metrics_by_mode.png / first_relevant_rank.png / sample_topk_scores.png	模式对比、首相关排名与示例 Top-K 分数图
contact_sheets/	查询图与候选图联系表

表 8 检索试点评测凭证文件清单

A.4 重要约束与复现实验注意事项

训练与评测可按以下顺序复现：先运行 `scripts/build_retrieval_dataset.py` 生成 8:1:1 的 TSV/JSONL，再由官方 `build_lmdb_dataset.py` 打包 LMDB；随后执行 `scripts/finetune/run_train_single_gpu.sh` 训练 3 轮，最后执行 `scripts/finetune/run_test_eval.sh` 生成基线与微调分数。微调索引由 `scripts/retrieval/build_category_index.py --checkpoint ... --output-dir data/index_data_finetuned` 生成，查询脚本从索引注册表自动读取对应权重，避免建索引和查询使用不同模型。

复现时需注意若干约束。`epoch3.pt` 约 2.2 GB、预训练权重约 719 MB，二者与 LMDB、中间特征均由 `.gitignore` 排除，换机器需按 `docs/finetune/02-微调训练.md` 和 `docs/finetune/04-Chinese-CLIP 补丁说明.md` 重新准备。test 集 934 条且候选池同为 934，不能与官方 MUGE 十万级候选池的 Recall@K 横向比较，且 test 已用于基线与两组微调的最终评测，后续调参只看 valid 或独立留出集。训练日志中的 Image2Text/Text2Image Acc 是 batch 内 32 候选口径，不等于全候选 R@K，两类数字不能直接混比。AI 复核试点的 qrels 由模型生成和审核，适合权重调优与错误分析，不等同于人工真值，最终报告应另建来源商品不重叠的测试查询集。