

实验1：数据采集与预处理实验指导

一、实验目标

1. 掌握多源数据（结构化、非结构化、特殊场景）的获取方法，能独立使用工具获取目标数据；
2. 熟练运用数据清洗技术处理缺失值、异常值等质量问题，掌握结构化/非结构化数据增强方法，了解自动化数据策展工具链的基本使用。
3. 完成数据集标准化与构建，理解数据隐私合规要求，具备基础的数据集评估能力。
4. 初步树立Data-Centric AI理念，理解数据质量对AI系统性能上限的决定性作用。

二、实验环境

硬件：计算机（建议8GB 以上内存，支持图像/音频处理）；

软件：PyCharm（Python 3.12）、Anaconda（Python 3.12）

核心库：pandas（数据处理）、numpy（数值计算）、requests（网络请求）、beautifulsoup4（网页解析）、scikit-learn（机器学习，含数据预处理）、PIL/OpenCV（图像处理）、nltk/spaCy（文本处理）、torchvision（图像增强）。

新增工具（选装）：Data-Juicer（自动化数据策展）、NVIDIA NeMo Curator（GPU加速数据流水线）、HuggingFace Datasets（数据集加载与流式处理）。

三、实验学时与安排

共6 学时，分3 个阶段完成：

- 阶段1：多源数据获取（2 学时）；
- 阶段2：数据清洗与增强（2 学时）；
- 阶段3：数据集建设与评估（2 学时）。

四、实验步骤

阶段1：多源数据获取（1.1 模块）

目标：获取至少2-3 类数据（结构化、非结构化文本、图像/音频），理解不同数据源的特点与获取逻辑。（2-3 人1 类数据）

任务1.1.1 结构化数据获取

结构化数据指具有明确格式（如表格、数据库）的数据，需通过合法渠道获取。

1.数据来源选择

-公开 API：如Kaggle公开数据集、政府开放数据平台、World Bank Open Data等；

-数据库文件：

下载CSV/Excel 格式文件（如泰坦尼克号数据集、鸢尾花数据集）等。

-HuggingFace Datasets（<https://huggingface.co/datasets>），支持流式加载和自动格式转换，已托管超过20万个数据集。

2.获取操作：

-方式1（API 获取）：例如调用API 下载结构化数据等。

-方式2（文件读取）：例如用pandas 读取本地CSV 文件等。

-方式3（HuggingFace加载）：使用datasets.load_dataset()直接加载远程数据集。

3.输出：存储为CSV/Excel 文件，记录数据字段说明（如“Age：乘客年龄，数值型”）。

任务1.1.2 非结构化数据获取

非结构化数据无固定格式，需针对文本、图像、音频等类型设计获取方案。

1.文本数据（网页爬取）

-选择合规网站（如博客、公开文档），遵守robots.txt 协议；

-用requests+BeautifulSoup 爬取文本内容（以爬取某技术博客为例）；

-**基于LLM的智能爬取**：使用大模型自动识别页面结构并提取目标字段，替代纯规则式解析。注意：爬取前除检查robots.txt外，还需关注目标网站是否发布了AI训练数据opt-out声明。

2.图像数据（公开数据集）

-下载小型图像数据集（如[CIFAR-10](https://www.cs.toronto.edu/~kriz/cifar.html) [Flowers-17](https://www.robots.ox.ac.uk/~vgg/data/flowers/17/)）；

-**方法**：官方直接下载、手动下载与组织、使用 TensorFlow/Keras（自动下载）、使用PyTorch（自动下载）、使用scikit-learn 加载等。

-HuggingFace多模态数据集（如COCO 2026版子集、LAION-5B子集）

3.输出：文本存储为TXT，图像按类别分文件夹存储，记录数据来源与格式。

任务1.1.3 特殊场景数据获取（选做）

针对多模态、传感器等特殊数据，重点理解数据关联性。

1.多模态数据（图文对）：

- 下载[COCO 数据集](https://cocodataset.org/)的小样本子集（含图像及对应描述文本）；

- 验证数据关联：检查图像路径与文本描述的对对应关系。

2. 传感器模拟数据：

- 如：生成模拟温度传感器数据（含时间戳、温度值、设备ID）。

3.合成数据生成 **（选做）**

合成文本数据：使用大模型（如DeepSeek-V4、Qwen3）生成指定领域的训练数据，使用提示词控制生成数据的多样性。

合成图像数据：使用Stable Diffusion 3或Flux等扩散模型生成图像，结合ControlNet控制生成条件。

合成表格数据：使用CTGAN、TVAE等生成模型合成结构化数据。

输出要求：记录合成数据的生成策略，并与真实数据进行质量对比（分布一致性、多样性指标）。

3. 输出：多模态数据按“ 图像-文本”配对存储，传感器数据存为 CSV ，标注数据采集场景（如“室内温度监测”）。

阶段2：数据清洗与增强（1.2 模块）

目标：解决数据质量问题，通过增强提升数据多样性，量化评估增强效果。

任务1.2.1 数据质量问题处理

针对阶段1 获取的数据，处理缺失值、异常值、重复值等。

1. 结构化数据清洗（以泰坦尼克号数据集为例）

- 缺失值处理：如用pandas 检测并填充（数值型用中位数，类别型用众数）等。

- 异常值处理：如用IQR 法检测并处理数值型异常（如Fare 字段）等。

- 重复值处理：如删除重复行等。

- LLM辅助数据清洗。使用大模型进行智能缺失值推断、异常检测和标签纠错。

2. 非结构化文本清洗

- 特殊字符与噪声处理等。

-文本规范化等

3. 非结构化图像数据清洗

- 元数据清理（隐私保护）

- 质量评估与筛选

- 重复图像检测等

4. 视频等其他非结构化数据及多模态数据清洗

5. 自动化数据策展流水线实践。

使用Data-Juicer搭建自动化清洗流水线，包含至少5个算子（如去重、过滤、规范化、质量筛选、语言识别）。

或使用NVIDIA NeMo Curator构建GPU加速数据流水线，支持大规模文本和图像数据的加载、过滤、去重与转换。

对比手工清洗与自动化流水线的效率差异。

6. 输出：清洗后的数据集，记录清洗前后的关键指标（如缺失值比例、异常值数量）。

任务1.2.2 数据增强方法实践

针对不同类型数据设计增强策略，并量化评估效果。

1. 结构化数据增强：

- 特征组合：生成新特征（如泰坦尼克号数据中“家庭规模=SibSp+Parch+1”）等

- 归一化：用scikit-learn对数值特征标准化等。

2. 图像数据增强：

- 用torchvision.transforms实现旋转、裁剪、加噪等

3. 文本数据增强：

- 同义词替换（用nltk）等

4. 增强效果量化评估 **（选做）**

- 图像：用简单分类模型（如CNN）对比增强前后在验证集的准确率等；

- 文本：计算增强前后文本的BLEU分数（与原文本的相似度）或分类模型困惑度等。

阶段3：数据集建设（1.3 模块）

目标：标准化数据格式，划分数据集，完成文档化，确保合规性。

任务1.3.1 数据标准化

统一数据格式、特征与标签规范。

1. 格式统一：

- 结构化数据：统一为CSV 格式，字段名小写，用下划线分隔（如passenger_id）；
- 图像数据：转换为PNG 格式，统一尺寸（如224×224）；
- 文本数据：存储为JSON 格式（含“text”“label”字段）；
- **多模态数据标准化**。使用Data-Juicer的formatter算子统一多模态数据格式（如WebDataset格式、Parquet格式）。

2. 特征标准化：

- 数值特征：用Min-Max 归一化到[0,1]范围（结构化数据）。
- 文本特征：转换为词向量（如用spaCy 生成嵌入）。

3. 标签规范化：

- 分类标签：转换为整数编码（如“存活”=1，“死亡”=0）。
- 合成数据标注。如果引入了合成数据，需增加合成数据与真实数据的混合策略和标注一致性检查。

任务 1.3.2 数据集构建与文档化

1. 数据集划分：

- 按 8:1:1 比例划分训练集、验证集、测试集（以结构化数据为例）。

2. 构建数据加载器：

- 用PyTorch Dataset 类封装图像数据集。

3. 数据集文档化：

- 编写README.md，包含：
 - 数据来源与授权协议（如“CIFAR-10 数据集，CC BY 4.0 协议”）；
 - 数据格式说明（字段定义、图像尺寸、文本长度范围）；
 - 清洗与增强步骤记录；
 - 隐私说明（如“无敏感个人信息”）。
- **数据集卡片（Data Card）**。在README.md基础上，增加标准化数据集卡片，涵盖数据来源、收集方法、标注流程、使用限制、伦理审查等维度。可参考HuggingFace Data Card模板。

-**数据溯源（Data Provenance）**。记录数据的完整处理链路，包括每一步清洗、增强和转换操作的参数与版本。EU AI Act Article 50要求AI生成内容具备机器可读标记，数据溯源是合规的基础。

4. 隐私合规专项检查。

- ✓ 数据来源是否具备合法授权；
- ✓ 是否遵守目标平台的robots.txt和AI训练数据使用声明；
- ✓ 合成数据是否符合最新监管要求（如印度2026年IT修正规则对AI生成信息的处理义务）；
- ✓ 是否涉及个人信息，如涉及是否已完成匿名化或合成替代；
- ✓ 数据使用协议是否满足课程作业的授权范围。

五、重点与难点说明

重点关注

1.数据标准化：确保不同来源数据格式一致（如日期格式统一为YYYY-MM-DD），特征尺度对齐（避免数值型特征因量级差异影响模型）等。

2. 增强效果评估：需设计对比实验（如固定模型架构，对比增强前后的训练效果），避免无效增强（如文本增强导致语义失真）等。

3. 数据隐私与合规：

-敏感数据处理：对含个人信息的数据进行匿名化（如删除姓名、身份证号）；

-合规性检查：爬取数据前确认网站 robots.txt（如 Disallow: /private 路径禁止爬取），数据集使用需遵守授权协议（如非商业用途）。

-关注全球AI数据合规最新动态，包括我国版权工作“十五五”规划中关于AI训练数据合理使用制度的表述、EU AI Act Article 50透明度要求、印度合成数据规则等。

4. **Data-Centric AI理念**。AI效果的上限由数据质量决定，而非模型参数规模。

以“数据质量报告”的形式，量化评估数据集在完整性、一致性、代表性和时效性四个维度上的表现。

难点突破

1. 非标数据解析：

-非标准日志文件：用正则表达式提取关键信息；

-特殊图像格式：用PIL 或 OpenCV 转换格式。

2. 多模态联合增强：确保不同模态增强后语义一致（如文本描述“红色汽车”对应图像增强后仍为红色汽车），可通过规则约束（如文本修改颜色词时同步调整图像颜色）。
3. 自动化策展流水线的算子调优。Data-Juicer等工具提供大量算子，如何根据数据特点选择和组合算子、平衡清洗效果与效率是实践难点。
4. 合成数据质量与隐私风险评估。合成数据可能引入分布偏差或泄露原始数据信息，需建立评估机制。

六、实验报告要求

1. 说明小组成员构成，明确每个成员完成的任务；
2. 记录数据获取全流程（含代码片段、遇到的问题及解决方案）；
3. 对比清洗前后的数据质量指标（如缺失值比例、异常值数量变化）；
4. 展示增强效果评估结果（如表格对比增强前后模型准确率）；
5. 附数据集README.md 文档及最终数据集结构截图，数据集下载链接；
6. 附自动化数据策展流水线配置说明及效率对比（如使用）；
7. 附数据集卡片（Data Card）和隐私合规检查清单；
8. （选做）：合成数据生成策略及质量对比报告。

七、参考资料

1. 公开数据集平台：[Kaggle](https://www.kaggle.com/)、[UCI Machine Learning Repository](https://archive.ics.uci.edu/)
2. [Scikit-learn 数据预处理文档](https://scikit-learn.org/stable/modules/preprocessing.html)
3. [PyTorch 数据加载与增强教程](https://pytorch.org/tutorials/beginner/basics/data_tutorial.html)
4. [网络数据安全管理条例]
https://www.gov.cn/zhengce/zhengceku/202409/content_6977767.htm
5. [个人信息保护合规审计管理办法]
https://www.cac.gov.cn/2025-02/14/c_1741233507681519.htm

6. 数据隐私保护相关

<https://www.wma.net/policies-post/wma-declaration-of-helsinki/>

<https://grants.nih.gov/policy-and-compliance/policy-topics>

7. Data-Juicer官方文档——大规模多模态数据处理工具

8. NVIDIA NeMo Curator官方文档——GPU加速数据策展工具

9. Data-Centric AI Manifesto (Malerba et al., Electronics 2026, 15(9), 1913)——DCAI
方法论框架

10. 版权工作“十五五”规划（国家版权局，2026年8月）——AI训练数据版权规则

11. EU AI Act Article 50——AI生成内容透明度要求